



福州大学本科生毕业设计（论文）

题 目： 从全局采样到局部搜索：组合优化视

角下的表格特征工程

姓 名： 曹致远

学 号： 112200803

学 院： 计算机与大数据学院

专 业： 计算机科学与技术

年 级： 2022 级

校内指导教师： _____（签名）

校外指导教师： _____（签名）

2026 年 6 月 1 日

福州大学本科生毕业设计（论文）诚信承诺书

学生姓名	曹致远	年 级	2022 级	学 号	112200803
所在学院	计算机与大数据学院			所学专业	计算机科学与技术
毕业设计（论文）题目		中文：从全局采样到局部搜索：组合优化视角下的表格特征工程			
		外文：From Global Sampling to Local Search: Combinatorial			
		Optimization Perspective based Tabular Feature Engineering			
学生承诺 我承诺在毕业设计（论文）过程中遵守学校有关规定，恪守学术规范，未存在买卖、代写、作假等行为。在本人的毕业设计（论文）中未剽窃、抄袭他人的学术观点、思想和成果，未篡改实验数据。如有违规行为发生我愿承担一切责任，接受学校的处理。 学生（签名）： 2026 年 5 月 18 日					
指导教师承诺 我承诺在指导学生毕业设计（论文）过程中遵守学校有关规定，恪守学术规范，经过本人认真的核查，该同学未存在买卖、代写、作假等行为，毕业设计（论文）中未发现剽窃、抄袭他人的学术观点、思想和成果的现象，未发现篡改实验数据。 指导教师（签名）： 2026 年 5 月 18 日					

从全局采样到局部搜索：组合优化视角下的表格特征工程

摘要

在当前机器学习实践中，数据质量与特征表征直接决定了模型性能的上限，使得自动化特征工程成为突破人工瓶颈的关键环节。然而，该领域面临的核心挑战在于：如何在规模呈指数级爆炸的离散特征组合空间中，以可控的计算成本高效搜索出高性能的特征表达式。现有方法，无论是基于符号操作的贪婪搜索，还是基于强化学习与遗传算法的智能策略，大多依赖枚举或简单启发式探索，导致搜索缺乏有效监督、极易陷入局部最优。

针对上述困境，本论文提出了一种名为“全局采样-局部搜索”的创新范式，其核心贡献具体体现在以下三个方面：首先，本文首次将生成流网络引入该领域，利用其按奖励比例采样的性质，实现了对离散空间的下游性能导向型全局采样，为后续搜索提供了多样化的高质量初始种群；其次，本文构建了基于序列自编码器的光滑可微分隐空间，将高维离散组合优化问题转化为可利用代理模型梯度进行引导的连续优化问题；最后，本文设计了融合生成与进化的迭代优化框架，该框架以生成流网络的全局采样结果为起点，通过在隐空间中进行多轮进化，有机整合了生成模型的广泛探索能力与梯度上升的精细优化能力。

为验证方法有效性，本研究在多个涵盖分类与回归任务的公开表格数据集上进行了实验。结果表明，相较于现有主流自动化特征工程方法，本文方案在性能上取得了最优效果。本工作不仅为自动化特征工程提供了高效实用的新工具，更为广泛的离散组合优化问题提供了基于梯度引导连续化隐空间搜索的全新解决思路，在理论上丰富了智能搜索方法体系，在实践中为构建高效自适应自动机器学习（AutoML）管道奠定了坚实基础。

关键词：全局采样，局部搜索，生成流网络，自编码器，组合优化

From Global Sampling to Local Search: Combinatorial Optimization Perspective based Tabular Feature Engineering

Abstract

In current machine learning practice, data quality and feature representation determine the model performance ceiling, making automated feature engineering a critical link to break manual bottlenecks. However, the core challenge lies in efficiently searching for high-performance feature expressions within an exponentially expanding discrete space at controllable computational costs. Existing methods, whether based on symbolic greedy search or intelligent strategies like reinforcement learning and genetic algorithms, largely rely on enumeration or simple heuristics, resulting in a lack of effective supervision and a tendency to fall into local optima.

To address these dilemmas, this paper proposes an innovative "Global Sampling-Local Search" paradigm, with its core contributions embodied in three aspects: First, it pioneeringly introduces Generative Flow Networks to the field, utilizing their reward-proportional sampling property to achieve performance-oriented global sampling in discrete spaces, providing a diverse and high-quality initial population for subsequent search. Second, it constructs a smooth differentiable latent space based on sequence autoencoders, transforming the high-dimensional discrete combinatorial optimization problem into a continuous optimization problem guided by proxy model gradients. Finally, it designs an iterative optimization framework merging generation and evolution, which starts from the global sampling results of Generative Flow Networks and performs multi-round evolution in the latent space, organically integrating the broad exploration of generative models with the fine-grained optimization of gradient ascent.

To verify the effectiveness of the method, experiments were conducted on multiple public tabular datasets covering classification and regression tasks. The results show that compared with existing mainstream automated feature engineering methods, the proposed scheme achieves optimal results in both performance and efficiency. This work not only provides a highly efficient and practical tool for automated feature engineering but also offers a new solution for broad discrete combinatorial optimization problems based on gradient-guided continuous latent space search, theoretically enriching the intelligent search methodology and practically laying a solid foundation for building efficient adaptive AutoML pipelines.

Key words: Global Sampling, Local Search, GFlowNet, Autoencoder, combinatorial Optimization

目 录

摘 要	I
Abstract	II
第1章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	1
1.3 本文核心贡献	2
第2章 基础知识背景	3
2.1 生成流网络	3
2.2 树状长短期记忆网络	4
2.3 基于隐空间的测试时优化	5
第3章 FeatEvolve: 一种基于全局采样与局部搜索的表格特征工程框架	6
3.1 GflowNet 驱动的全局采样	6
3.2 基于结构化隐空间的局部搜索	8
3.3 特征种群的迭代进化	9
第4章 实验设计与可视化分析	11
4.1 概要	11
4.2 数据集	11
4.3 对比算法	11
4.4 消融实验	12
4.5 表征空间可视化	13
第5章 结论与展望	16
参考文献	17
附录 1	18
致 谢	20

第 1 章 绪论

1.1 研究背景与意义

特征工程作为连接表格型数据与机器学习模型的桥梁，其价值在当今数据驱动的决策环境中愈发凸显^[1]。许多现实世界的问题，其内在规律并非直接线性地映射在给定的观测变量上，而是隐藏在复杂的、非线性的特征交互与组合之中。自动化特征工程的意义，正是在于通过对原始特征构造交叉表达式生成组合特征^[2-3]，自动发现这些潜在的有效模式，从而将人类从繁重的、基于直觉的试错劳动中解放出来，将数据科学的焦点从繁琐的数据准备转向更具创造性的模型设计与业务洞察。

自动化特征工程的挑战是多维度的。首先，它需要处理特征空间的组合爆炸问题。即便是中等数量的原始特征，经过多层函数（如算术运算、聚合函数、非线性变换等）的组合与迭代应用，可能生成的特征数量会呈指数级增长，这使得穷举式生成和评估在计算和存储上变得不可行。其次，生成的特征不仅要具有统计上的预测效力，还应尽可能具备可解释性，以便让领域专家能够理解和信任模型的决策依据。最后，自动化方法需要具备高效的探索策略，能够从海量的潜在特征组合中，快速识别出那些真正能提升下游任务（如分类、回归）性能的特征子集，避免陷入盲目搜索或过早收敛于次优解。

因此，对该领域的研究不仅聚焦于算法的自动化程度，更关注其智能化水平。理想的方法应能模拟人类专家的部分认知过程，例如理解特征间的组合含义、评估特征交互的统计显著性，并在探索效率与生成特征的质量之间取得平衡。这推动了从早期的基于规则和穷举的方法，到引入元学习、强化学习、神经网络控制器等更复杂范式的发展^[4]。这些技术进步旨在使特征工程过程变得更高效、更鲁棒，同时又能保持线性模型般清晰可解释的预测系统，从而在准确性、效率与可信赖性这三个关键维度上为实际应用提供坚实支撑。

本课题的研究任务，就是通过在离散空间中全局采样潜在的高性能特征转换表达式，再在局部连续隐空间中搜索局部最优特征交叉表达式，在进化迭代中生成强判别力的特征组合表达式，从而提升下游机器学习模型的预测精度。

1.2 国内外研究现状

表格特征工程可以提高机器学习模型的预测性能，该过程已从早期的人工设计转变为自动化和智能化的方式。目前国内外研究主要围绕启发式搜索、元学习和强化学习这三种方法进行。Kanter 等人利用启发式搜索、扩展缩减的思想提出的深度特征合成（Deep Feature Synthesis）通过在关系型数据中沿关联路径递归应用数学函数来自动构建特征^[5]；Katz 等开发的 ExploreKit 框架则通过预定义的算子组合原始特征生成大量候选集，并利用分类器预测特征有用性以缓解空间爆炸问题^[3]；Horn 等推出的 autofeat 库通过多步骤生成非线性特征池并进行鲁棒性筛选，旨在保留线性模型解释性的同时提升精度^[6]。在基于元学习方面，Nargesian 等提出的 LFE 技术通过在大量历史数据集上训练神经网络，学习特定特征变

换对分类性能的影响，从而在无需模型评估的情况下直接推荐有效的特征算子^[7]。在基于强化学习的搜索策略方面，Khurana 等将特征工程建模为变换图的性能驱动探索过程，首次利用强化学习在过去案例中学习高效的探索路径^[4]；Chen 等提出的 Neural Feature Search (NFS) 采用循环神经网络作为控制器，通过强化学习最大化模型性能，以捕获高阶变换并解决搜索空间受限的问题^[8]；针对特征空间的解释性与效率，Wang 等提出的组级强化特征生成（Group-wise Reinforcement Feature Generation）通过级联马尔可夫决策过程实现嵌套的特征生成与选择^[9]；而 Azim 等进一步引入交互感知机制，在多智能体强化学习架构中通过统计度量奖励特征间的交互强度，模拟机器学习专家的认知过程以构建逻辑严密且可解释的特征空间^[10]。

1.3 本文核心贡献

- 首次将生成流模型（GFlowNet）引入表格特征工程，利用 GFlowNet 按奖励比例采样的性质覆盖高奖励值的特征结构区域，达到全局采样的效果。
- 为特征表达式的逆波兰式设计了一套语法推导式，利用语法规则掩码无效动作，保障生成特征表达式的有效性。
- 创新性地引入序列自编码器构造一个平滑的隐空间，将离散的组合优化问题转化成可微空间中的连续优化问题，降低了优化难度。
- 创新性地引入树形长短期记忆网络（Tree-LSTM）作为自编码器的编码器部分，从而捕捉特征表达式的树状结构，将特征表达式映射到一个结构化的表征空间。
- 创新性地引入代理模型用于评估特征表达式的下游性能，为隐空间内的多步梯度上升优化提供梯度值。

第 2 章 基础知识背景

2.1 生成流网络

生成式流网络（Generative Flow Networks, 简称 GFlowNet）作为一个新兴的概率生成框架，为解决复杂组合空间中的多样性采样问题提供了有力的数学工具^[11]。与传统的强化学习（RL）方法不同，传统 RL 通常把最大化期望回报当作目标，这会使策略收敛到一个唯一的最优解，也就是所谓的模式坍塌问题。GFlowNet 的主要原理是学习一个随机策略，使采样得到任何目标对象 x 的概率和回报 $R(x)$ 成正比。GFlowNet 把对象建立过程建模成有向无环图 DAG 轨迹，从初始空状态 s_0 出发，经过一系列离散动作慢慢演化，最后达到终止状态空间 $\mathcal{X}$ 内的某个完整对象。在网络进行学习时，通过分配状态间的流，来保证在整个搜索空间中进行具有奖励感知的探索。

GFlowNet 在形式化定义中引入了前向策略 $P_F(s_{t+1}|s_t)$ 和后向策略 $P_B(s_t|s_{t+1})$ ，用来描述状态转移。前向策略指当前部分建立状态向下一步状态迁移的概率，而后向策略指把已建立对象进行拆解的逆向概率。采样概率 $P(x)$ 要严格符合奖励分布 $R(x)/Z$ ，这里 Z 是配分函数，也就是所有可能对象的回报总和，整个流网络就需要满足流量守恒条件。这说明在任意状态下，进入该状态的总流量应当等于流出的总流量。该模式可以让 GFlowNet 找到全局最优解，并且有合理概率找到其他具有竞争力的次优解，进而形成拥有预测能力和结构多样性的候选池。

为了实现上述分布匹配目标，轨迹平衡损失（Trajectory Balance Loss, 简称 TB Loss）被广泛应用于 GFlowNet 的训练中，其推导过程基于路径流量的全局一致性。考虑一条从起始状态 s_0 到终止状态 s_n 的完整轨迹 $\tau = (s_0, s_1, \dots, s_n)$ ，根据流平衡理论，该轨迹上的前向概率流与总流量 Z 的乘积应等于该终止对象的回报值与其后向概率流的乘积。这一关系可以表示为如下数学恒等式：

$$Z \prod_{t=1}^n P_F(s_t|s_{t-1}) = R(s_n) \prod_{t=1}^n P_B(s_{t-1}|s_t) \quad \text{公式 (2-1)}$$

该式直观地说明了，沿着特定路径生成对象的概率（经总流归一化后）应当与其在该路径下被拆解回初始状态的概率及最终奖励保持一致。

在实际参数化训练时，为了将上述等式转化为可优化的目标函数，通常对其两边取对数以简化连乘运算，得到：

$$\log Z + \sum_{t=1}^n \log P_F(s_t|s_{t-1}) = \log R(s_n) + \sum_{t=1}^n \log P_B(s_{t-1}|s_t) \quad \text{公式 (2-2)}$$

通过引入可学习的参数 θ 来表示策略和标量 Z_θ ，我们可以构造出一个轨迹平衡损失函数：

$$\mathcal{L}_{TB}(\tau) = \left(\log Z_\theta + \sum_{t=1}^n \log P_F(s_t|s_{t-1}; \theta) - \log R(s_n) - \sum_{t=1}^n \log P_B(s_{t-1}|s_t; \theta) \right)^2 \quad \text{公式 (2-3)}$$

模型通过采样轨迹让该损失近似达到最小值，会让前向策略和后向策略在状态空间里达到

平衡。该轨迹级别的优化方法比局部的流匹配方法拥有更好的数值稳定性，可以引导模型在广阔的搜索空间里学习到符合预设奖励分布的生成逻辑，以保证最终生成的因子或结构化对象具有很高的鲁棒性和代表性。

2.2 树状长短期记忆网络

树状长短期记忆网络（Tree-LSTM）属于对传统线性长短期记忆网络（LSTM）进行的一种主要泛化，该设计意图在于解决链式模型难以有效对自然语言层次化语法特性进行建模的局限性^[12]。传统序列模型中的信息只可以在单一的时间维度上进行线性传播，并且把句子看作单词的有序排列。但是，语言学理论说明，自然语言一般呈现出来递归的树状结构，词汇经过组合形成短语，从而构成完整的句子语义。Tree-LSTM 把拓扑结构从线性链条扩展到任意树状网络，让一个节点的隐藏状态由多个子节点的隐藏状态共同决定，这样可以更自然地捕捉语言的语义组合规律。

Tree-LSTM 在具体实现时保留了标准 LSTM 的主要组件，包括输入门、输出门、记忆细胞和隐藏状态，但是内部的门控机制和更新逻辑经过了结构化重构。标准 LSTM 模型只含有一个遗忘门，Tree-LSTM 给每个子节点设置单独的遗忘门，父节点便可以有选择地筛选各子分支的信息流。该模式在实际运用中拥有明显长处。比如，在处理依存树时，模型可以学到保留具有主要语义的动词信息，并且适度忽略功能性限定词。

根据应用场景中树的分支特性，Tree-LSTM 演化出了两种主要的变体，即 Child-Sum Tree-LSTM 与 N -ary Tree-LSTM。Child-Sum Tree-LSTM 特别适用于子节点数量不固定或子节点之间没有明确顺序的情况，例如依存句法树。对于任意节点 j ，其转移过程首先会对所有子节点 $k \in C(j)$ 的隐藏状态进行求和，得到聚合后的隐藏状态 $\tilde{h}_j = \sum_{k \in C(j)} h_k$ 。随后，输入门 i_j 、输出门 o_j 及候选记忆状态 u_j 分别通过如下公式计算：

$$i_j = \sigma(W^{(i)}x_j + U^{(i)}\tilde{h}_j + b^{(i)}) \quad \text{公式 (2-4)}$$

$$o_j = \sigma(W^{(o)}x_j + U^{(o)}\tilde{h}_j + b^{(o)}) \quad \text{公式 (2-5)}$$

$$u_j = \tanh(W^{(u)}x_j + U^{(u)}\tilde{h}_j + b^{(u)}) \quad \text{公式 (2-6)}$$

对于每个具体的子节点 k ，其专属遗忘门 f_{jk} 由下式确定：

$$f_{jk} = \sigma(W^{(f)}x_j + U^{(f)}h_k + b^{(f)}) \quad \text{公式 (2-7)}$$

最终父节点的记忆细胞 c_j 通过累加各子节点经过门控过滤后的状态得到，而节点的最终隐藏状态 h_j 则由输出门控制：

$$c_j = i_j \odot u_j + \sum_{k \in C(j)} f_{jk} \odot c_k \quad \text{公式 (2-8)}$$

$$h_j = o_j \odot \tanh(c_j) \quad \text{公式 (2-9)}$$

另一种变体 N -ary Tree-LSTM 则针对分支数受限且子节点具有明确位置顺序的情况进行了优化，例如二叉成分句法树。在这种架构中，模型为每个位置的子节点分配了独立的参数矩阵 U_l ，从而能够学习到更精细的位置敏感特征。以二叉树为例，其输入门的计算公式为：

$$i_j = \sigma(W^{(i)}x_j + \sum_{l=1}^N U_l^{(i)}h_{jl} + b^{(i)}) \quad \text{公式 (2-10)}$$

而针对第 k 个子节点的遗忘门 f_{jk} 则不仅参考当前输入，还会考虑所有子节点的隐藏状态总和：

$$f_{jk} = \sigma(W^{(f)}x_j + \sum_{l=1}^N U_{kl}^{(f)}h_{jl} + b^{(f)}) \quad \text{公式 (2-11)}$$

该种精细化的建模方式可以使模型捕捉到左侧名词短语和右侧动词短语之间存在的细微语义互动关系。树结构变成单一分支的链式结构以后，这两种变体的数学形式会简化成标准的 LSTM 方程。Tree-LSTM 在特征工程中按照特征表达式的语法树结构进行操作，它所捕捉到的表示表现出对语法的敏感性，可以区分语义相同而写法不同的表达式，或者发现有潜力的特征组合。

2.3 基于隐空间的测试时优化

在进行隐空间测试时，优化工作的主要价值在于它打破了高维参数空间更新计算方面的瓶颈。在常规测试过程中，适应一般要显式地对参数进行微调，推理阶段会造成很大的计算负担、过拟合风险。把任务特征编码进一个低维并且紧凑的连续隐空间，优化过程就转而在压缩的隐空间里进行梯度更新。该方法明显提高收敛速度，并且它让模型在较少测试样本的情况下，通过调整隐向量分布，可以快速获取当前任务的特定分布特点。

针对复杂逻辑结构的组合优化问题，隐空间梯度优化方式比传统离散搜索算法有更明显的优点。该方式建立了一个平滑且连续的神经映射空间，让原本很难直接进行优化的底层逻辑结构可以通过梯度搜索来进行优化^[13]。对比在海量离散组合空间中进行盲目搜索，连续隐空间包括丰富语义信息，通过利用该隐空间的梯度定向搜索能够高效地找到满足优化目标的表征向量。该方法使神经网络在测试阶段可以实时调整内部逻辑处理路径，同时利用梯度方向性来防止搜索空间爆炸引起的计算无法进行。

就提高系统整体性能而言，隐空间里的梯度优化已经成为一种不用干预模型基础权重就能让推理能力得到提高的重要方式。近期一些研究大模型隐式推理的工作发现，利用梯度信息在潜在表示空间内进行精细迭代，可以优化推理过程中的逻辑连贯性和准确度^[14-15]。该策略保留了深度神经网络端到端学习所具有的灵活性，并且加入按照特定输入进行逻辑修正的动态特点。模型通过在隐空间里持续利用梯度迭代对表示进行优化，可以在测试过程中自主提高智能水平，并且处理高复杂推理任务时会拥有更好的成功率和泛化性能。虽然大语言模型的隐式推理和本文在隐空间里利用梯度引导优化特征表达式结构的方法有很大不同，但前者让我想到把离散搜索问题通过构造隐式空间变成连续优化问题。

第 3 章 FeatEvolve: 一种基于全局采样与局部搜索的表格特征工程框架

表格特征工程的目标是在复杂的数学表达式的组合空间 $\mathcal{X}$ 中挖掘高性能的有效特征组合表达式 $\alpha(\hat{f})$ (如 $\sqrt{f_1^2 + f_2^2}$, $\min_max(f_3)$), 当将特征表达式应用到原始数据集 $D = \langle F, y \rangle$ 生成多个组合特征 $\hat{f}_i$ 并将 $\hat{F} = \{\hat{f}_1, \hat{f}_2, \dots, \hat{f}_n\}$ 合并到原始特征集合, 即 $\mathcal{F} = F \cup \hat{F}$ 后, 使得新数据集 $\mathcal{D} = \langle \mathcal{F}, y \rangle$ 相比于原始数据集 D 在相同的下游机器学习模型 $\mathcal{M}$ 训练的性能值 $L_{\mathcal{M}}$ (如 $F1$ 和 R^2) 最大化。因此, 特征工程的目标是生成一个特征组合表达式集合 $\hat{F}$ 使得:

$$F^* = \arg \max_{\hat{F}} L_{\mathcal{M}}(F \cup \hat{F}, y) \quad \text{公式 (3-1)}$$

如图3-1所示, 为达到这个目标, 本文提出了 FeatEvolve 框架, 通过全局采样和局部搜索的二阶段流程生成高性能特征表达式。

3.1 GflowNet 驱动的全局采样

特征工程自动化研究一般会从很大的候选组合空间里生成初始表达式集合, 这个集合会被用来进行后续的迭代优化工作, 从而获得高质量的特征组合表达式。若使用完全随机采样的方法来生成初始种群, 虽然可以较好地维持表达式的多样性, 但是无法有效控制所生成样本的性能质量, 进而使优化效率低下。相对而言, 运用价值学习的强化学习方法, 例如 Q-Learning 和 DQN, 可以借助策略迭代在组合空间中迅速收敛到局部比较理想的特征组合, 使表达式在目标任务上的性能得到明显提高^[16-17]。不过, 这些方法在搜索时容易过早进入局部最优解, 出现模式坍塌的情况, 使得最后得到的表达式集合缺少多样性, 也影响模型在复杂任务上的表征能力和泛化性能。特征工程初始种群的生成过程中, 在保证表达式性能的前提下维持结构多样性, 是一个主要的挑战。本文引入 GflowNet 作为采样器。GflowNet 的采样策略满足:

$$P_{\theta}(x) \propto R(x), \quad P_{\theta}(x) = \sum_{\tau \in \mathcal{T}(x)} P_{\theta}(\tau) \quad \text{公式 (3-2)}$$

其中 $\tau = (s_0 \rightarrow \dots \rightarrow x)$ 为采样轨迹而 $\mathcal{T}(x)$ 是采样终点为 x 的轨迹集合^[11], $R(x)$ 为表达式 x 的奖励值。在具体设计上, 为适配不同任务类型的评估需求, 奖励函数被设定为与下游机器学习性能直接挂钩的指标。对于分类任务, 所生成的特征表达式在加入原始数据集后, 其奖励由下游分类器训练所得结果的 $F1$ 分数衡量; 对于回归任务, 则采用预测值与真实值之间决定系数 R^2

传统强化学习方法, 比如策略梯度优化, 目的是找到一条可以使累积奖励达到最大的最优路径, 但是生成流网络 GflowNet 有按照奖励比例进行采样的特点。这说明高奖励对应的表达式被采样的概率较高, 但不唯一, 所以它可以由组合空间覆盖多个高奖励区域, 而不同于单一峰值。该模式能够较好地平衡挖掘高奖励解和探索多样结构之间的冲突, 并且

会形成一个在奖励和多样性之间达到良好平衡的候选表达式集合。该集合可以支持后续进行进一步优化，并且拥有高潜力的高质量初始化种群。

训练流程如图3-2阶段一所示，本文使用 LSTM 网络作为序列编码器，为统一表达式结构，表达式被构造为逆波兰式序列输入序列编码器表征当前状态，随后将序列表征输入 GflowNet 学习一个前向概率流 $P_F(s_{t+1} | s_t; \theta)$ 和一个后向概率流 $P_F(s_t | s_{t+1}; \theta)$ ，训练目标是学习一个目标分布 $P(\alpha)$ 使得：

$$P(\alpha) = \sum_{\tau: s_n = \alpha} P_F(\tau) = \frac{R(\alpha)}{Z}, \quad \text{s.t. } d(\alpha) < d_{max} \quad \text{公式 (3-3)}$$

其中 $P(\alpha)$ 为表达式 α 被采样的概率， Z 是一个可学习的参数，表示配分函数， $d(\cdot)$ 表示特征表达式的阶数， d_{max} 表示表达式最高阶数限制。本文引入了轨迹平衡损失函数训练 GflowNet 从而生成多样的高性能特征表达式作为后续优化的初始特征种群。在本文中，GflowNet 每一步采样的动作空间包括了原始特征集合、操作符集合（见附录 1）以及终结符，当生成终结符或序列中的运算阶数（运算符数量）达到限制值时产生一个特征表达式。但是为保证生成表达式的有效性，本文为特征表达式的逆波兰式生成制定了一套基于上下无关文法的掩码规则，在每一步的生成过程中掩码无效动作，文法规则如下：

文法规则

Start $\rightarrow$ NumExpr | CatExpr

NumExpr $\rightarrow$ NumFeature | NumExpr UnaryNumOp
| NumExpr NumExpr BinaryNumOp | CatExpr NumExpr CatNumOp

CatExpr $\rightarrow$ CatFeature | CatExpr CatExpr BinaryCatOp

UnaryNumOp $\rightarrow$ log | sqrt_abs | min_max | reciprocal

BinaryNumOp $\rightarrow$ plus | minus | multiply | division | mod_column

BinaryCatOp $\rightarrow$ count_hash | nunique

CatNumOp $\rightarrow$ cat2num_mean

NumFeature $\rightarrow f \in F_{num}$

CatFeature $\rightarrow f \in F_{cat}$

文法中 F_{num} 代表数值型特征， F_{cat} 代表类别型特征。

在 GflowNet 的生成过程中，为防止生成全零特征或冗余特征如 $f_1 \cdot (f_2 + f_3)$ 和 $f_1 \cdot f_2 + f_1 \cdot f_3$ ，本文设计了一种基于余弦相似度的去冗余机制，具体而言，首先将通过特征表达式计算出表达式对应的表格特征列，若该特征列数值全为 0 则判定为冗余特征。随后计算该表格列与记忆队列中的表格列的余弦相似度，若相似度为 1 则说明该表格列为冗余列，不加入记忆队列；否则加入。

Algorithm 1 基于余弦相似度的去冗余机制

Require: 表格特征列集合 C , 特征表达式 $\alpha(\cdot)$, 特征种群数量 pop 。

Ensure: 冷启动特征列种群 M 。

```

1:  $M \leftarrow C$ 
2:  $flag \leftarrow 1$ 
3: for  $i = 1$  to  $pop$  do
4:    $\alpha_i \leftarrow \text{GflowNet}()$ 
5:    $f_i \leftarrow \alpha_i(C)$ 
6:   for  $c_j \in M$  do
7:      $\text{sim} \leftarrow \frac{f_i \cdot c_j}{\|f_i\| \|c_j\|}$ 
8:     if  $\text{sim} = 1$  then
9:        $flag \leftarrow 0$ 
10:      break
11:    end if
12:  end for
13:  if  $flag = 1$  then
14:     $M \leftarrow M \cup \{f_i\}$ 
15:  end if
16: end for
17: return  $M$ 
    
```

3.2 基于结构化隐空间的局部搜索

本文在利用生成式流网络 GFlowNet 进行全局采样并得到高性能初始特征种群之后, 主要目标转为对表达式结构进行精细化调优。在含有离散算子、变量的组合空间里执行显式搜索, 会遇到组合爆炸、计算开销的问题。受^[13]启发, 本文建立了一个连续且可微的隐空间, 将复杂的离散优化问题转换为高效的梯度算子操作, 以此来解决在离散空间中进行盲目搜索时遇到的效率瓶颈。具体来看, 本文使用自编码器架构来构造表达式序列的隐空间: 把初始种群里特征表达式的逆波兰表达式序列重构成树状结构, 并且用 Tree-LSTM 当作结构化编码器 $\mathcal{F}_{\text{seq}}$ 以捕获表达式深层的层次语义特征, 配合 LSTM 解码器 $\mathcal{G}_{\text{seq}}$ 实现序列重构, 从而建立起完备的序列自编码机制。针对优化过程中下游性能指标 s 对表达式隐向量 h 的梯度 $\frac{\partial s}{\partial h}$ 无法直接解析求解的难题, 受^[18]的研究启发, 本文引入了一个可微代理模型 ϑ , 输入为隐向量 h , 输出为特征列加入原始数据集后的性能值, 即 $L_{\mathcal{M}}(F \cup \hat{f}_h, y)$, 来拟合隐空间与性能分值之间的映射关系。通过在代理模型上执行反向传播获取梯度估计 $\frac{\partial \vartheta}{\partial h}$, 进而引导隐向量向更高性能的方向精确演进。如图3-2的阶段二中, 在预训练过程中, 使用重建损失 $\mathcal{L}_{rec}$ 训练序列自编码器:

$$\mathcal{L}_{rec} = - \sum_x \sum_{r=1}^{|x|} \log P_{\mathcal{G}_{\text{seq}}}(x_r \mid \mathcal{F}_{\text{seq}}(x)) \quad \text{公式 (3-4)}$$

其中 x 为 GFlowNet 全局采样阶段中采集到的特征表达式序列, x_r 代表特征表达式序列中第 r 个词元 (token)。另外, 我们使用均方误差损失 $\mathcal{L}_{mse}$ 预训练代理模型 ϑ :

$$\mathcal{L}_{mse} = \sum_x (s_x - \vartheta(\mathcal{F}_{\text{seq}}(x)))^2 \quad \text{公式 (3-5)}$$




图 3-1 FeatEvolve 框架

其中 s_x 为 GFlowNet 全局采样阶段中采集到的特征表达式 x 对应的奖励值，即特征表达式在下游机器学习模型的真实性能。 ϑ 是一个由 5 层全连接多层感知机构成的代理模型。在预训练阶段，本文使用冷启动阶段采样所得的特征表达式集合和性能值进行训练，联合优化重建损失 $\mathcal{L}_{rec}$ 与均方误差 $\mathcal{L}_{mse}$ ，并通过一个参数 λ 调节两者的比例：

$$\mathcal{L} = \mathcal{L}_{rec} + \lambda \mathcal{L}_{mse} \quad \text{公式 (3-6)}$$

预训练使用了早停策略防止过拟合，即若在 20 个训练周期内验证集上的损失没有改善则自动停止训练。另外为了平衡两个损失项， λ 被设置为 $\mathcal{L}_{rec}$ 和 $\mathcal{L}_{mse}$ 的比值。

如图3-2阶段三，在测试优化阶段，冻结序列自编码器与代理模型的参数。首先利用 Tree-LSTM 编码器将待优化特征表达式序列映射到连续的隐空间。随后对特征表达式的隐向量执行多步梯度上升优化：

$$e_{x'} = \sum_{h_r \in H_x} \left(h_r + \eta \frac{\partial \vartheta}{\partial h_r} \right) \quad \text{公式 (3-7)}$$

其中 $e_{x'}$ 是优化后的隐向量， $H_x = \{h_1, h_2, \dots, h_{|x|}\}$ 表示与特征遍历字符串 x 对应的每个时间步的隐藏状态集合， η 表示学习率。FeatEvolve 通过梯度上升过程最大化代理模型的性能估计，从而优化特征表达式的隐向量 $e_{x'}$ 并从 $e_{x'}$ 中解码出优化后的特征表达式。

3.3 特征种群的迭代进化

本研究设计的进化流程如图 3-1 所示。初始种群由冷启动获取的 n 个特征构成，通过性能评估筛选出排名前 k 的个体组建精英种群，并将其映射至隐空间进行梯度优化。余下的 $(n - k)$ 个非精英特征则通过与原始特征集随机交叉重组，生成高阶特征表达式以强化




图 3-2 FeatEvolve 训练流程

对更高阶的表达式组合空间的探索。每轮迭代结束后，将优化特征与新探索特征整合并重新排序，动态更新精英种群。待多轮演化终止，对特征种群按性能降序排列并依次引入数据集；若新特征无法带来下游模型性能的实质提升，则判定为演化饱和并终止集成，以确保特征集的判别力与简洁性。

Algorithm 2 特征筛选

Require: 原始特征集合 F ，生成特征种群集合容量 n ，生成特征种群集合 $\hat{F} = \{\hat{f}_1, \hat{f}_2, \dots, \hat{f}_n\}$ ，特征集下游性能 $s(\cdot)$ 。

Ensure: 最终特征集合 F^* 。

- 1: $F^* \leftarrow F$
- 2: $\hat{F} \leftarrow \text{sort}(\hat{F})$
- 3: **for** $i = 1$ to n **do**
- 4: **if** $s(F^*) > s(F^* \cup \hat{f}_i)$ **then**
- 5: **break**
- 6: **end if**
- 7: $F^* \leftarrow F \cup \{\hat{f}_i\}$
- 8: **end for**
- 9: **return** F^*

第 4 章 实验设计与可视化分析

4.1 概要

为了充分验证 FeatEvolve 框架在不同类型、不同任务的表格数据集上的性能，本文在 5 个分类任务数据集和 5 个回归任务数据集上开展实验，为统一评估，下游机器学习模型统一采用随机森林算法。对于分类型数据集，评估标准为 $F1$ ；对于回归型数据集，评估标准为 R^2 。实验结果如表4-1所示。

4.2 数据集

本文选择十个有代表性的公开数据集当作基准测试集，包括通用算法验证和特定行业应用等方面。其中 Openml_607、Openml_616、Openml_618、Openml_620 及 Openml_637 都来源于 OpenML 这个机器学习托管平台，包括了不同规模、特征维度和分布特征的标准实验样本。在具体领域应用上，German Credit 和 Credit Default 数据集把重点放在金融信贷风险评估上，分别利用人口统计学变量、历史还款行为来对个体信用违约进行建模；Amazon Employee 模拟了复杂企业环境下的资源访问权限自动化决策过程；Ionosphere 数据集来自高频天线阵列所获取的雷达回波信号，体现了物理科学中包括高维模式识别的任务；Messidor Features 包括了从医疗眼底影像中提取的病理特征描述符，并且专门用于进行糖尿病视网膜病变的辅助诊断工作。本文选用的数据集可以保证实验评价在金融安全、信息管理、物理探测和生物医学等不同异构数据环境中拥有泛化能力并且保持鲁棒。

4.3 对比算法

我们将 FeatEvolve 算法与 7 种现有的最优算法进行对比实验：（1）Raw 表示不进行特征工程；（2）LDA^[19]通过矩阵分解提取特征向量；（3）AFT^[6]通过先进行特征交叉生成探索特征空间，再通过 $L1$ 正则化多步筛选特征；（4）NFS^[8]通过训练一组以递归神经网络（RNN）为核心的控制器，利用强化学习来为每个原始特征自动搜索并生成最优的变换序列；（5）TTG^[4]将特征工程转化为在特征转换路线图上的路径搜索问题，引入强化学习作为搜索策略，通过在历史任务上学习到的经验，在复杂的转换空间中自动、高效地定位能最大程度降低预测误差的特征组合；（6）GRFG^[9]将特征工程建模为群组级联的马尔可夫决策过程，利用强化学习在分组特征上自动搜索并演化出最优的变换序列，从而在兼顾计算效率的同时构建出具有可解释性的高阶特征空间；（7）InHRecon^[10]通过构建具有级联马尔可夫决策过程的层次强化学习框架，将特征空间重构定义为生成有意义特征与控制特征集规模的嵌套过程，从而实现自动化且符合逻辑的数据表示转换。分析4-1的数据可知，FeatEvolve 特征工程框架显著提升了下游机器学习模型的预测性能，并且在所有数据集达到了 SOTA（State Of The Art）效果，显示了 FeatEvolve 强大的特征生成能力。其中，在分类任务上，FeatEvolve 展现出显著的性能提升，相较于无特征工程方案平均提高了约 10 个点。

表 4-1 FeatEvolve 与当下主流的特征工程方法的实验对比，最优与次优结果均已标记。

评估指标	数据集	样本数/特征数	Raw	LDA	AFT	NFS	TTG	GRFG	InHRecon	FeatEvolve
$F1$	Openml_607	1000/50	0.634	0.376	0.658	0.675	0.639	0.680	0.671	0.722
	Openml_616	500/50	0.575	0.385	0.585	0.593	0.559	0.603	0.605	0.670
	Openml_618	1000/50	0.627	0.372	0.665	0.640	0.587	0.668	0.673	0.708
	Openml_620	1000/25	0.634	0.425	0.663	0.698	0.656	0.714	0.694	0.719
	Openml_637	500/50	0.514	0.494	0.564	0.581	0.575	0.589	0.625	0.640
R^2	German Credit	1001/24	0.741	0.627	0.751	0.765	0.731	0.769	0.773	0.793
	Amazon Employee	32769/9	0.945	0.920	0.943	0.935	0.806	0.946	0.947	0.951
	Credit Default	30000/25	0.804	0.744	0.799	0.799	0.809	0.800	0.812	0.816
	Ionosphere	351/34	0.923	0.730	0.827	0.942	0.938	0.946	0.954	0.955
	Messidor Features	1150/19	0.658	0.580	0.679	0.746	0.726	0.757	0.738	0.761

这一结果不仅证实了特征工程对分类任务至关重要，也揭示了其在分类问题上具有更大的优化潜力与提升空间。而在回归型数据集上，FeatEvolve 在部分数据集如 German Credit 和 Messidor Features 上效果显著，但在其他数据集上提升较小，本文认为相对于回归模型，分类模型更需要特征工程产生具有较强判别性的组合特征辅助分类，因此特征工程的作用在回归型任务效果不如分类型任务更加显著。

另外，本文观察到 LDA 与 AFT 在部分数据集上效果反而不如无特征工程方案，本文认为这两种特征工程方案都可能筛选了部分原始特征导致部分数据信息丢失，而其他特征工程方案均是在保留原始特征的基础上生成组合特征，因此性能更加稳定。

4.4 消融实验

为了验证各个模块的有效性，我们分别在 3 个分类数据集和 3 个回归数据集上针对无特征工程方案 Raw 和以下 2 个 FeatEvolve 变体开展消融实验：(1) $FeatEvolve^{-G}$ ：用随机采样代替 GflowNet 采样；(2) $FeatEvolve^{-T}$ ：用 LSTM 网络替换 Tree-LSTM 作为自编码器的编码器部分。对于分类型数据集 Openml_607、Openml_616 和 Openml_618，本文使用 $F1$ 评估，对于回归型数据集 German Credit、Amazon Employee 和 Credit Default，本文使用 R^2 评估。

实验结果如图 4-1 所示。在所有测试数据集上，完整模式 Ours 的性能都比其他变体要好，主要因为全局采样和局部搜索结合的方式具有优势。通过比较无特征工程方案 Raw 与其他三种方案可以看出，应用自动化特征工程方法可以改善模型表现，特别是在处理 Openml_616 等复杂数据集时，Raw 方案的性能出现明显下降，说明了特征工程的重要作用。

其次， $FeatEvolve^{-G}$ 的性能通常比完整模式低，在回归类数据集上的差距较大。分析发现 GFlowNet 利用按奖励比例采样的方式，可以更覆盖高奖励的特征结构区域，为后续优化提供高质量的初始种群，而随机采样因为缺少引导通常会陷入低效搜索。

进一步分析结构化自编码器的影响， $FeatEvolve^{-T}$ 虽然在性能上优于随机采样方案，但仍普遍逊于完整方案 Ours，这验证了引入 Tree-LSTM 的核心价值。Tree-LSTM 可以捕捉

特征表达式所具有的树状层次结构，该模型在隐空间里形成的表征拥有比较强的语法先验，因而能够更加准确地协助代理模型进行梯度引导优化。总的来看，GFlowNet 驱动的全局多样性采样与基于 Tree-LSTM 结构化隐空间的局部精细化搜索一起组成了 FeatEvolve 模式的高性能基础。

最后，我们还能观察到，在 Amazon 和 Credit Default 数据集上各个消融变体与完整版 FeatEvolve 相差极小，由此可知在个别数据集上特征工程的优化空间有限。本文认为在部分数据集上机器学习模型已经能够充分探索到数据的分布模式，因此特征工程对下游模型的促进作用并不明显。




图 4-1 消融实验

4.5 表征空间可视化

为了验证 FeatEvolve 框架的有效性，我们通过 t-SNE 技术降维可视化隐空间。具体而言，我们以 Messidor Features 数据集为实验对象，将冷启动产生的和多轮进化后最终筛选采用的特征表达式通过预训练后的结构化编码器 Tree-LSTM 映射到隐空间，然后通过 t-SNE 将隐向量降到二维，第三个维度为特征表达式对应的下游性能值。如图4-2所示，经观察可得，最终采纳的特征表达式相较于从全局采样所得表达式的对应数值点，其性能值普遍更高。这表明，在特征进化与梯度优化的协同过程中，特征表达式的性能表现呈现出持续的优化趋势。

图4-3呈现了本研究构建的隐空间二维可视化结果。图中对三个在空间位置上相邻的数据点进行了标记，并且标注了它们对应的解析表达式，以说明模型所学习到的表示规律。观察表明，这些邻近点所对应的表达式不是随机分布的，而是语法树结构上表现出明显的相似性。该结果表明 Tree-LSTM 编码器的主要能力是利用门控机制沿着语法树进行递归式信息聚合，模型可以准确地识别和编码表达式的层次化结构语义。拥有相似树结构的表达式，




图 4-2 3D 可视化

在通过 Tree-LSTM 编码之后，会在隐空间中被映射到彼此邻近的表示向量上。

该可视化结果为模型的内部工作机制提供了直观证据。它表明，Tree-LSTM 不仅仅是在进行表面的字符串编码，而是成功地学习到了数学表达式的结构相似性这一关键抽象特征。在隐空间中，这种结构相似性被转化为几何上的接近性（即欧氏距离或余弦相似度较小），从而形成了一个具有良好结构保序性的特征流形。这解释了为何在隐空间中进行后续梯度优化操作是有效的：因为模型已将一个离散的、符号化的结构空间，连续、平滑地嵌入到一个低维的向量空间中，其中几何关系忠实地反映了语法逻辑关系。

在图4-3中可以看出，多数最终采纳的特征表达式在低维空间中的表征点与冷启动采样阶段的初始表征点几乎重合，尽管它们所对应的实际数学表达式并不相同。这一结果表明，基于多步梯度上升的优化过程能够促使隐向量有效跳出初始采样点的局部邻域，从而解码出结构不同且更具表达能力的特征形式进一步地，图4-2显示，尽管优化后的表达式在表征空间中与冷启动起点非常接近，其对应的性能分数却有显著提升。该现象进一步证实，多步梯度优化能够通过微调隐向量的方式，在保持表征几何邻近性的同时，显著改善特征的质量与下游任务的表现，从而验证了本文所采用优化策略的有效性与鲁棒性。这也说明，在连续表征空间中进行梯度引导的搜索，能够在有限的几何变动范围内实现表达式的有效演化与性能优化。




图 4-3 2D 可视化

如表4-2所示，本文对比了隐空间梯度优化前后表达式在句法形态上的演变。受限于篇幅，此处仅展示若干长度适中的代表性样本。实验观察表明，梯度优化主要引起特征组合表达式中终端节点（特征元素）的变化，而对内部节点（操作符）的扰动较小，表达式的长度与阶次均保持稳定。从抽象语法树（AST）的视角来看，表达式的拓扑结构在优化过程中未发生显著改变。上述现象一方面证实隐空间能够将高维的组合搜索空间有效压缩为富含语义的低维表征；另一方面揭示了隐空间内的梯度更新具有高度的局部细腻性，充分验证了该隐空间的拓扑平滑性。

表 4-2 表达式优化前后形式及性能提升对照表

优化前	优化后	性能提升
$f_7/(f_2 - f_6)$	$f_6/(f_2 - f_6)$	↑ 14.2%
$\log(f_5 \times (f_2 \bmod f_{15})) \bmod f_{11}$	$\log(f_{11} \times (f_2 \bmod f_{15})) \bmod f_{11}$	↑ 3.6%
$f_{17} \times \sqrt{ f_4 + f_{16} }$	$f_{16} \times \sqrt{ f_8 + f_{16} }$	↑ 17.6%
$f_{12} - (f_{11} \bmod (f_{17} - f_9)) + \sqrt{ 1/f_{10} }$	$f_{12} - (f_{10} \bmod (f_{17} - f_{19})) + \sqrt{ 1/f_{10} }$	↑ 5.1%
$\min_max(f_7 \times \log f_{17}) \bmod f_9$	$\min_max(\min_max(f_7 \times \log f_{17})) \bmod f_9$	↑ 11.6%
$f_{18} \times (\min_max(f_1 - f_{55} \times f_{49} \times (f_{49} - f_{50}))/f_{23})$	$f_{49} \times (\min_max(f_1 - f_{55} \times f_{49} \times (f_{49} - f_{49}))/f_{19})$	↑ 7.9%
$\log f_{20}/\sqrt{ \min_max(\sqrt{ f_{38} }) }$	$\log f_{39}/\sqrt{ \min_max(\sqrt{ f_{38} }) }$	↑ 12.5%
$1/(\min_max(f_{22})/(f_{42} + f_{41}))$	$1/(\min_max(f_{22})/(f_{22} + f_{41}))$	↑ 10.1%
$f_{38} \bmod \min_max(f_{16} + \min_max(f_{23})/f_{38})$	$f_{23} \bmod \min_max(f_{41} + \min_max(f_{41})/f_{38})$	↑ 4.7%
$\min_max(f_{27} + f_{13}) \bmod \sqrt{ f_{23} }$	$f_{23} + (\min_max(1/f_{40}) \bmod f_{23})$	↑ 15.5%

第 5 章 结论与展望

本文为了解决自动化表格特征工程中经常出现的离散组合空间爆炸和搜索容易陷入局部最优解的问题，从组合优化角度提出了将全局采样与局部搜索结合起来的创新方法，形成了 FeatEvolve 端到端特征生成模式。本文先使用生成流网络代替传统强化学习作为初始种群采样器，该网络具有按奖励比例采样的特点，在覆盖高价值特征结构区域时防止了模式坍缩问题，并且结合上下文无关文法的动作掩码和余弦相似度去冗余方式，给后续优化提供了高性能且具备多样性的高质量初始特征集合。本文使用了 Tree-LSTM 的结构化自编码器，该模型把离散的特征表达式逆波兰序列映射到光滑可微的连续隐空间，并且通过代理模型拟合隐向量和下游性能的映射关系，以实现离散组合优化问题的连续梯度引导优化，由此突破了传统离散搜索的效率瓶颈。本文综合生成和进化逻辑来设计迭代进化流程，使用精英种群梯度调优和非精英特征交叉重组进行动态更新，从而在探索广度和优化精度上达到平衡。实验结果表明该方法在 10 个包括分类和回归任务的公开表格数据集上都取得了当前最优性能，分类任务与没有特征工程的基线相比平均提高约 10 个百分点，说明了全局采样和局部搜索共同发挥作用的效果。

现有工作仍有一些扩展空间，未来可以在多个方面继续深入：第一，当前模式的搜索空间只包括基础算术运算和统计类算子，后续可以加入时序滑动窗口、多表关联聚合等更复杂的算子类型，以适应工业界多源异构数据的特征构造要求，进而提高方法的通用性。第二，现有的特征评估通常把提高性能当作唯一的准则，以后可以加入特征冗余度和新颖性等评估标准，给冷启动过程提供更丰富的奖励信号。第三，特征工程的方法和任务场景、特征含义有着非常紧密的联系。可以尝试利用大语言模型拥有的丰富语义先验和数据或特征 ID 的语义信号，来更高效、直观地发现有效的特征组合，并更好地把数据、任务和特征工程进行关联。

参考文献

- [1] Domingos P. A few useful things to know about machine learning[J]. Communications of the ACM, 2012, 55(10): 78-87.
- [2] Dor O, Reich Y. Strengthening learning algorithms by feature discovery[J]. Information Sciences, 2012, 189: 176-190.
- [3] Katz G, Shin E C R, Song D. Explorekit: Automatic feature generation and selection[C]. in: 2016 IEEE 16th international conference on data mining (ICDM). 2016: 979-984.
- [4] Khurana U, Samulowitz H, Turaga D. Feature engineering for predictive modeling using reinforcement learning[C]. in: Proceedings of the AAAI conference on artificial intelligence: vol. 32: 1. 2018.
- [5] Kanter J M, Veeramachaneni K. Deep feature synthesis: Towards automating data science endeavors[C]. in: 2015 IEEE international conference on data science and advanced analytics (DSAA). 2015: 1-10.
- [6] Horn F, Pack R, Rieger M. The autofeat python library for automated feature engineering and selection [C]. in: Joint European Conference on Machine Learning and Knowledge Discovery in Databases. 2019: 111-120.
- [7] Nargesian F, Samulowitz H, Khurana U, et al. Learning feature engineering for classification.[C]. in: Ijcai: vol. 17. 2017: 2529-2535.
- [8] Chen X, Lin Q, Luo C, et al. Neural feature search: A neural architecture for automated feature engineering [C]. in: 2019 IEEE International Conference on Data Mining (ICDM). 2019: 71-80.
- [9] Wang D, Fu Y, Liu K, et al. Group-wise reinforcement feature generation for optimal and explainable representation space reconstruction[C]. in: Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2022: 1826-1834.
- [10] Azim E, Wang D, Liu K, et al. Feature interaction aware automated data representation transformation[C]. in: Proceedings of the 2024 SIAM International Conference on Data Mining (SDM). 2024: 878-886.
- [11] Bengio Y, Lahlou S, Deleu T, et al. Gflownet foundations[J]. Journal of Machine Learning Research, 2023, 24(210): 1-55.
- [12] Tai K S, Socher R, Manning C D. Improved semantic representations from tree-structured long short-term memory networks[C]. in: Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). 2015: 1556-1566.
- [13] Macfarlane M, Bonnet C. Searching latent program spaces[J]. Advances in Neural Information Processing Systems, 2026, 38: 103463-103520.
- [14] Zhang G, Meng F, Wan G, et al. Latentevolve: Self-evolving test-time scaling in latent space[J]. arXiv preprint arXiv:2509.24771, 2025.
- [15] Li H, Li C, Wu T, et al. Seek in the dark: Reasoning via test-time instance-level policy gradient in latent space[J]. arXiv preprint arXiv:2505.13308, 2025.
- [16] Watkins C J C H, et al. Learning from delayed rewards[J]. 1989.
- [17] Mnih V, Kavukcuoglu K, Silver D, et al. Playing atari with deep reinforcement learning[J]. arXiv preprint arXiv:1312.5602, 2013.
- [18] Wei Y, Peng B, Xie R, et al. Deep active optimization for complex systems[J]. Nature Computational Science, 2025, 5(9): 801-812.
- [19] Blei D M, Ng A Y, Jordan M I. Latent dirichlet allocation[J]. Journal of machine Learning research, 2003, 3(Jan): 993-1022.

附录 1

本附录对 FeatEvolve 框架特征搜索空间中所使用的全部操作符进行系统性的数学定义。这些操作符与前文第 3.1 节中所给出的上下无关文法规则一一对应。根据操作数的类型与数量，所有操作符被划分为一元数值操作符、二元数值操作符、二元类别操作符和二元混合操作符四类，共计 12 个。一元数值操作符包括对数变换、绝对值平方根、归一化和倒数变换，主要用于通过非线性变换挖掘数据中潜在的分布特征并缓解偏态问题；二元数值操作符包括加法、减法、乘法、除法和取模，用于构造数值特征间的二阶交叉项以捕捉线性叠加与交互效应；二元类别操作符包括哈希计数和去重计数，通过统计手段挖掘类别变量间的共现模式与分布多样性；二元混合操作符为分组均值，能够将类别特征的分组结构信息转化为连续的数值特征。以下逐个给出各操作符的具体数学公式及实现细节。

（1）对数变换（**log**）：对输入数值特征取绝对值的自然对数，用于压缩数据尺度并缓解偏态分布。为避免对零取对数产生未定义错误，实现中对零值元素施加微小偏移 $\epsilon = 10^{-5}$ 后再执行变换：

$$\log(f) = \ln(|f|)$$

（2）绝对值平方根（**sqrt_abs**）：对输入数值特征取绝对值后开平方根，提供一种温和的非线性压缩效果，适用于数据中存在负值且需要抑制极端值的场景：

$$\text{sqrt_abs}(f) = \sqrt{|f|}$$

（3）归一化（**min_max**）：将输入数值特征列线性缩放至 $[0, 1]$ 区间，消除不同特征间的量纲差异：

$$\text{min_max}(f) = \frac{f - \min(f)}{\max(f) - \min(f)}$$

（4）倒数变换（**reciprocal**）：对输入数值特征取倒数，用于捕捉特征值与目标变量之间可能存在的反比关系。与对数变换类似，对零值元素同样施加 $\epsilon = 10^{-5}$ 的微小偏移以避免除零错误：

$$\text{reciprocal}(f) = \frac{1}{f}$$

（5）加法（**plus**）：将两个数值特征逐元素相加，捕捉特征间的线性叠加效应，满足交换律：

$$f_1 + f_2$$

（6）减法（**minus**）：将两个数值特征逐元素相减，捕捉特征间的差异信息，不满足交换律，在逆波兰式序列中操作数的顺序具有语义区分作用：

$$f_1 - f_2$$

（7）乘法（**multiply**）：将两个数值特征逐元素相乘，捕捉特征间的交互效应，满足交

换律：

$$f_1 \times f_2$$

(8) 除法 (**division**)：将两个数值特征逐元素相除，捕捉特征间的比率关系，不满足交换律。实现中对除数为零的元素施加 $\epsilon = 10^{-5}$ 的微小偏移：

$$\frac{f_1}{f_2}$$

(9) 取模 (**mod_column**)：对两个数值特征逐元素取模，捕捉特征的周期性或离散化特征，不满足交换律。实现中仅对除数非零的元素执行取模运算，除数为零的位置输出零值：

$$(f_1 \bmod f_2)_i = \begin{cases} f_{1,i} \bmod f_{2,i}, & f_{2,i} \neq 0 \\ 0, & f_{2,i} = 0 \end{cases}$$

(10) 哈希计数 (**count_hash**)：接收两个类别型特征，首先通过组合函数 $h(c_1, c_2) = c_1 + c_2 + c_1 \times c_2$ 构造哈希值，随后统计每个哈希值在数据集中出现的频次，并将该频次映射回每一行，满足交换律，能够有效捕获两个类别特征的共现模式：

$$\text{count_hash}(c_1, c_2) = \text{Count}(h(c_1, c_2)), \quad h(c_1, c_2) = c_1 + c_2 + c_1 \times c_2$$

(11) 去重计数 (**nunique**)：接收两个类别型特征，以 c_1 为分组键，统计每组中 c_2 的不同取值个数，并将结果映射回对应行，不满足交换律，能够反映一个类别特征在另一个类别特征各水平下的多样性程度：

$$\text{nunique}(c_1, c_2)_i = |\{c_{2,j} : c_{1,j} = c_{1,i}\}|$$

(12) 分组均值 (**cat2num_mean**)：接收一个类别型特征与一个数值型特征，以类别特征 c 为分组键，计算数值特征 f 在各组内的均值，并将该均值映射回对应行，不满足交换律。该操作本质上执行了一种类似于目标编码的特征转换，能够将类别特征的分布信息融入数值空间：

$$\text{cat2num_mean}(c, f)_i = \frac{1}{|S_v|} \sum_{j \in S_v} f_j, \quad S_v = \{j : c_j = v\}, \quad v = c_i$$

其中 S_v 表示类别特征取值为 v 的样本索引集合。

致 谢

行文至此，我的本科四年即将画上句点。回望过去这段时光，不仅是人工智能技术突飞猛进的四年，更是我自身不断蜕变、成长的四年。四年前，我成功转入计算机专业，从那时起，命运的齿轮悄然转动。几乎与 ChatGPT 横空出世同步，初入计科的我开启了属于自己的深度学习之旅——这或许正是我与人工智能缘分的起点。然而对于当时刚刚踏入这个领域的我，前路更多是未知与迷茫。

转入计算机的第二年，我在 Kaggle 大模型竞赛中拿到了一枚金牌。这枚金牌，仿佛冥冥之中的一种暗示，让我更加确信自己与人工智能之间那份特殊的缘分，也照亮了我未来想要走下去的道路。于是，比赛之后，我毅然投身于自己感兴趣的人工智能课题研究。在接下来漫长而充实的一年里，我埋头阅读了几十篇文献，一点点摸索属于自己的思路，再把那些闪烁的想法一行行写成代码。我清楚地感受到，这一年，我在沉默中进阶，在探索中蜕变。终于，在去年冬天，我的第一篇完全由自己独立完成的论文，在人工智能顶级会议 AAAI 的“AI for Urban Planning”研讨会上发表了。那一刻，所有深夜的灯光、反复的推敲、得失之间的徘徊，都化为了前行路上最坚实的足迹。

成功之路通向璀璨光辉，但沿途却写满挫折与迷茫。我也曾无数次怀疑自己的选择。还记得最初的自己，一篇论文对着有道翻译琢磨一整天仍然一知半解，深夜复现代码时面对满屏的报错，也曾手足无措。或许，当曾经的我看到如今的自己，心里会感到一丝欣慰。我要感谢许许多多这一路帮助、包容、支持我的人，我要感谢我的朋友彭博远让我第一次接触到了机器学习并一直支持我坚持这条道路，感谢我的科研引路人政鸿学长帮助我掌握了基本的科研技能，感谢筱玥学姐鼓励我冲击顶会，以及国磊学长对我投稿期间的支持和帮助。感谢我的父母大力资助我前往新加坡参会交流，感谢我的毕设导师傅仰耿老师对我毕设的指导，为我的本科生涯画上了一个完整的句号。最后，我还要感谢 loongtex 为我的毕设论文写作提供了便捷、舒适的写作体验，希望有朝一日 loongtex 能成为比肩 overleaf 的 LaTeX 科研写作平台。

从深夜的台灯到南洋的霓虹，从电脑屏前到新加坡 Expo 的国际会场，AI 科研的浪潮不仅让我走向更广阔的世界，认识更多对 AI 同样怀揣热忱的同侪，也让我找到了自己的人生意义所在。每个终点都只是新的存档，每个终章皆是新传的开篇。回头再看，全是精彩花絮；展望未来，皆是未完待续的诗篇。